

Laporan Proyek — Klasifikasi Kondisi Kulit Wajah (MobileNetV2 → TFLite)

Proyek: QayraMakeUp — TensorFlow MobileNetV2 Tanggal: 3 Juni 2026

a. Tujuan Proyek

Membangun model klasifikasi **kondisi kulit wajah** ke dalam 5 kategori — **acne, dry, normal, oily, sensitive** — menggunakan arsitektur **MobileNetV2** dengan *transfer learning*, lalu mengekspornya ke **TensorFlow Lite (skin_condition.tflite)** agar ringan dan dapat dijalankan di perangkat mobile/edge untuk aplikasi **QayraMakeUp**.

Model menerima input gambar wajah **224×224 piksel RGB** (dinormalkan ke rentang $[0,1]$) dan menghasilkan probabilitas *softmax* untuk 5 kelas.

b. Dataset & Sumbernya

Empat kelas memiliki sumber visual yang jelas, namun **kelas sensitive tidak memiliki dataset visual "kulit sensitif" yang valid**, sehingga digunakan **proxy** berbasis kemerahan kulit:

Kelas	Sumber	Keterangan
oily, dry, normal	Kaggle — <i>Oily-Dry-and-Normal-Skin-Types</i>	dataset wajah penuh
acne	Kaggle — <i>Acne Dataset</i>	banyak <i>close-up</i> kulit
sensitive	proxy: <i>redness</i> (TrainingDataPro) + <i>rosacea</i> (Roboflow)	tidak ada dataset "sensitif" langsung

Tantangan kelas sensitive dan penanganannya

- Masalah awal:** sumber *redness* hanya berisi **30 foto dari 10 orang** (3 angle per orang). Jumlah dan keragaman ini terlalu kecil dan sangat rawan **kebocoran data (leakage)** bila foto orang yang sama tersebar antar split.
- Penambahan sumber:** ditambahkan kelas **rosacea** dari dataset Roboflow *facial-skin-diseases* (kelas lain seperti acne/eksim/herpes/panu **diabaikan**). Setelah kurasi, kelas *sensitive* menjadi **192 gambar bersih** yang berasal dari **±89 grup unik** (gabungan rosacea, redness, dan data kurasi lama).
- Split group-aware (anti-leakage):** pembagian train/val/test dilakukan **per grup** menggunakan `group_id`, sehingga semua gambar dari satu subjek/satu gambar asli (termasuk augmentasinya) selalu berada di split yang sama.
- Augmentasi hanya di train:** bagian *train sensitive* diaugmentasi hingga genap, sedangkan **val & test memakai gambar asli saja** (tidak diaugmentasi) agar evaluasi jujur.

- **Augmentasi menjaga sinyal warna:** karena kemerahan adalah **fitur warna**, augmentasi dibatasi pada transformasi **geometric** (flip horizontal, rotasi kecil, zoom/crop ringan, translasi) + **brightness ringan**, **TANPA mengubah hue/saturation** agar sinyal kemerahan yang justru ingin dipelajari tidak rusak.

c. Pipeline Kurasi Data

Script: [tools/prepare_dataset.py](#)

1. **Kumpulkan pool** per kelas dari sumber mentah + **salin** 100 gambar kurasi manual lama (copy, bukan dipindah).
2. **Deteksi wajah** — detektor diganti dari **Haar Cascade** → **OpenCV DNN res10 SSD** yang jauh lebih kuat. Dampaknya signifikan: jumlah *no-face* yang salah dibuang turun drastis (mis. *oily* dari 101 → 10). Gambar tanpa wajah terdeteksi tetap dibuang (dihitung).
3. **Crop wajah** → **resize 224×224**, normalisasi semua gambar ke .jpg.
4. **Dedup perceptual-hash** hanya untuk **4 kelas besar** (*oily/dry/normal/acne*); kelas *sensitive* **tidak** di-dedup agar augmentasi & variasi angle dipertahankan.
5. **Manifest** `dataset/_clean/manifest.csv` (path, kelas, group_id, sumber) sebagai dasar split *group-aware*.

Hasil kurasi (pool bersih): *oily* **350**, *dry* **369**, *normal* **376**, *acne* **250**, *sensitive* **192** (≈89 grup unik).

d. Pembagian Akhir Dataset (70 / 20 / 10)

Script: [tools/split_dataset.py](#) — kumpulkan acak 200 per kelas besar, lalu split **140 train / 40 val / 20 test**.

Kelas	Train	Val	Test	Total
acne	140	40	20	200
dry	140	40	20	200
normal	140	40	20	200
oily	140	40	20	200
sensitive	140 (134 asli + 6 aug)	39 (asli)	19 (asli)	198

Total: **700 train / 199 val / 99 test**. Split *sensitive* terbukti **bebas leakage** (irisan grup antar split = 0).

Perbaiki labels.txt: file ditulis ulang dalam **urutan alfabet** (*acne, dry, normal, oily, sensitive*) agar **cocok dengan urutan baca flow_from_directory**. Ini sekaligus **menutup bug** urutan lama di mana *oily* dan *dry* tertukar.

e. Training

Arsitektur: MobileNetV2 (bobot ImageNet, `include_top=False`, *base di-freeze*) + head: GlobalAveragePooling2D → Dense(128, ReLU) → Dropout(0.5) → Dense(5, softmax).

- **Fase 1 (feature extraction):** 15 epoch, optimizer Adam, *base dibekukan*.
- **Fase 2 (fine-tuning):** *unfreeze* 50 layer terakhir, learning rate **1e-5**, 5 epoch.

Ringkasan hasil per fase:

Fase	Train acc	Val acc
Fase 1 — awal (ep1)	0.32	0.46
Fase 1 — akhir (ep15)	0.697 (~70%)	0.578 (~57.8%)
Fase 2 — akhir (ep20)	0.56	0.578

Temuan: akurasi *train* naik hingga **~70%** sementara akurasi *validasi* **mentok di kisaran 55–58%** (puncak ~57.8%) = mulai terjadi **overfitting ringan**. **Fine-tuning TIDAK menaikkan akurasi validasi** (tetap di ~57–57.8% sepanjang fase 2).


f. Evaluasi di Test Set

Script: [tools/evaluate.py](#) — 99 gambar test, `shuffle=False`, tanpa augmentasi.

Akurasi keseluruhan: 58.59%.

Kelas	Precision	Recall	F1-score	Support
acne	0.71	0.85	0.77	20
dry	0.44	0.70	0.54	20
normal	0.63	0.25	0.36	20
oily	0.48	0.55	0.51	20
sensitive	0.92	0.58	0.71	19
accuracy	—	—	0.59	99
macro avg	0.63	0.59	0.58	99
weighted avg	0.63	0.59	0.58	99

Confusion Matrix (baris = label asli, kolom = prediksi):



g. Analisis

- **Kelas terkuat:** `acne` (F1 **0.77**) dan `sensitive` (F1 **0.71**). Keduanya punya ciri visual yang relatif khas (tekstur jerawat; kemerahan), sehingga lebih mudah dipisahkan.
- **Sumber error utama:** trio `dry` / `normal` / `oily` saling **tumpang-tindih**. Pada confusion matrix terlihat `dry` 14 benar tapi 5 bocor ke `oily`; `oily` 11 benar dengan 7 bocor ke `dry`.
- **normal paling lemah** (recall **0.25**) — dari 20 sampel hanya 5 benar; sering tertukar menjadi `dry` (7) atau `oily` (6).
- **dry menjadi "keranjang" over-prediksi** — banyak kelas lain salah diprediksi sebagai `dry` (precision rendah 0.44 meski recall tinggi 0.70).
- Hal ini **wajar**: perbedaan visual antara kulit `dry`, `normal`, dan `oily` memang **halus** dan sangat bergantung pencahayaan/kualitas foto.

h. Keterbatasan

1. **Test set kecil** (~20 gambar/kelas, total 99) → angka metrik **berisik**; selisih beberapa gambar dapat menggeser persentase cukup besar.
2. **Bias sumber pada sensitive** — kelas ini berasal dari sumber berbeda (rosacea + redness), sehingga model bisa saja belajar **ciri sumber/dataset**, bukan murni "sensitivitas kulit". **Uji sebenarnya** adalah foto wajah baru di luar dataset.
3. **Fine-tuning belum efektif** — pada lr 1e-5, fase 2 tidak meningkatkan akurasi validasi.
4. Model yang disimpan adalah **epoch terakhir**, bukan epoch dengan validasi terbaik.

i. Rekomendasi Perbaikan

1. **Perbaiki data dry/normal/oily** (terutama `normal`): tambah jumlah, perbaiki kualitas & konsistensi pencahayaan, kurangi ambiguitas label.
2. **Fine-tuning lebih agresif & cerdas**: coba lr **1e-4**, dan gunakan ModelCheckpoint/EarlyStopping untuk **menyimpan model dengan val accuracy terbaik** (bukan epoch terakhir).
3. **Kumpulkan foto kulit sensitif asli** untuk menggantikan proxy redness/rosacea, agar kelas `sensitive` benar-benar merepresentasikan target aplikasi.
4. **Pertimbangkan konsolidasi kelas** (mis. menggabungkan kategori yang ambigu) bila sesuai dengan kebutuhan produk QayraMakeUp.

Laporan ini dibuat berdasarkan `training_log.txt`, `evaluate_report.txt`, `confusion_matrix.png`, `labels.txt`, dan script di folder `tools/`. Angka diambil langsung dari artefak hasil training/evaluasi.