

Laporan Proyek — Klasifikasi Kondisi Kulit Wajah (MobileNetV2 → TFLite)

Proyek: QayraMakeUp — TensorFlow MobileNetV2 Tanggal: 3 Juni 2026

a. Tujuan Proyek

Membangun model klasifikasi **kondisi kulit wajah** ke dalam 5 kategori — **acne, dry, normal, oily, sensitive** — menggunakan arsitektur **MobileNetV2** dengan *transfer learning*, lalu mengekspornya ke **TensorFlow Lite (skin_condition.tflite)** agar ringan dan dapat dijalankan di perangkat mobile/edge untuk aplikasi **QayraMakeUp**.

Model menerima input gambar wajah **224×224 piksel RGB** (dinormalkan ke rentang $[0, 1]$) dan menghasilkan probabilitas *softmax* untuk 5 kelas.

b. Dataset & Sumbernya

Empat kelas memiliki sumber visual yang jelas, namun **kelas sensitive tidak memiliki dataset visual "kulit sensitif" yang valid**, sehingga digunakan **proxy** berbasis kemerahan kulit:

Kelas	Sumber	Keterangan
oily, dry, normal	Kaggle — <i>Oily-Dry-and-Normal-Skin-Types</i>	dataset wajah penuh
acne	Kaggle — <i>Acne Dataset</i>	banyak <i>close-up</i> kulit
sensitive	proxy: <i>redness</i> (TrainingDataPro) + <i>rosacea</i> (Roboflow)	tidak ada dataset "sensitif" langsung

Tantangan kelas sensitive dan penanganannya

- Masalah awal:** sumber *redness* hanya berisi **30 foto dari 10 orang** (3 angle per orang). Jumlah dan keragaman ini terlalu kecil dan sangat rawan **kebocoran data (leakage)** bila foto orang yang sama tersebar antar split.
- Penambahan sumber:** ditambahkan kelas **rosacea** dari dataset Roboflow *facial-skin-diseases* (kelas lain seperti acne/eksim/herpes/panu **diabaikan**). Setelah kurasi, kelas *sensitive* menjadi **192 gambar bersih** yang berasal dari **±89 grup unik** (gabungan rosacea, redness, dan data kurasi lama).
- Split group-aware (anti-leakage):** pembagian train/val/test dilakukan **per grup** menggunakan `group_id`, sehingga semua gambar dari satu subjek/satu gambar asli (termasuk augmentasinya) selalu berada di split yang sama.
- Augmentasi hanya di train:** bagian *train sensitive* diaugmentasi hingga genap, sedangkan **val & test memakai gambar asli saja** (tidak diaugmentasi) agar evaluasi jujur.

- **Augmentasi menjaga sinyal warna:** karena kemerahan adalah **fitur warna**, augmentasi dibatasi pada transformasi **geometric** (flip horizontal, rotasi kecil, zoom/crop ringan, translasi) + **brightness ringan**, **TANPA mengubah hue/saturation** agar sinyal kemerahan yang justru ingin dipelajari tidak rusak.

c. Pipeline Kurasi Data

Script: [tools/prepare_dataset.py](#)

1. **Kumpulkan pool** per kelas dari sumber mentah + **salin** 100 gambar kurasi manual lama (copy, bukan dipindah).
2. **Deteksi wajah** — detektor diganti dari **Haar Cascade** → **OpenCV DNN res10 SSD** yang jauh lebih kuat. Dampaknya signifikan: jumlah *no-face* yang salah dibuang turun drastis (mis. *oily* dari 101 → 10). Gambar tanpa wajah terdeteksi tetap dibuang (dihitung).
3. **Crop wajah** → **resize 224×224**, normalisasi semua gambar ke .jpg.
4. **Dedup perceptual-hash** hanya untuk **4 kelas besar** (*oily/dry/normal/acne*); kelas *sensitive* **tidak** di-dedup agar augmentasi & variasi angle dipertahankan.
5. **Manifest** `dataset/_clean/manifest.csv` (path, kelas, group_id, sumber) sebagai dasar split *group-aware*.

Hasil kurasi (pool bersih): *oily* **350**, *dry* **369**, *normal* **376**, *acne* **250**, *sensitive* **192** (≈89 grup unik).

d. Pembagian Akhir Dataset (70 / 20 / 10)

Script: [tools/split_dataset.py](#) — kumpulkan acak 200 per kelas besar, lalu split **140 train / 40 val / 20 test**.

Kelas	Train	Val	Test	Total
acne	140	40	20	200
dry	140	40	20	200
normal	140	40	20	200
oily	140	40	20	200
sensitive	140 (134 asli + 6 aug)	39 (asli)	19 (asli)	198

Total: **700 train / 199 val / 99 test**. Split *sensitive* terbukti **bebas leakage** (irisan grup antar split = 0).

Perbaiki labels.txt: file ditulis ulang dalam **urutan alfabet** (*acne, dry, normal, oily, sensitive*) agar **cocok dengan urutan baca flow_from_directory**. Ini sekaligus **menutup bug** urutan lama di mana *oily* dan *dry* tertukar.

e. Training

Arsitektur: MobileNetV2 (bobot ImageNet, `include_top=False`, *base di-freeze*) + head: GlobalAveragePooling2D → Dense(128, ReLU) → Dropout(0.5) → Dense(5, softmax).

- **Fase 1 (feature extraction):** 15 epoch, optimizer Adam, *base dibekukan*.
- **Fase 2 (fine-tuning):** *unfreeze* 50 layer terakhir, learning rate **1e-5**, 5 epoch.

Ringkasan hasil per fase:

Fase	Train acc	Val acc
Fase 1 — awal (ep1)	0.32	0.46
Fase 1 — akhir (ep15)	0.697 (~70%)	0.578 (~57.8%)
Fase 2 — akhir (ep20)	0.56	0.578

Temuan: akurasi *train* naik hingga **~70%** sementara akurasi *validasi* **mentok di kisaran 55–58%** (puncak ~57.8%) = mulai terjadi **overfitting ringan**. Fine-tuning **TIDAK** menaikkan akurasi validasi (tetap di ~57–57.8% sepanjang fase 2).


f. Evaluasi di Test Set

Script: [tools/evaluate.py](#) — 99 gambar test, `shuffle=False`, tanpa augmentasi.

Akurasi keseluruhan: 58.59%.

Kelas	F F F1-score	Support
acne	0.7085727	20
dry	0.4375385	20
normal	0.62953571	20
oily	0.4795016	20
sensitive	0.9197997	19
accuracy	0.5859	99
macro avg	0.6395879	99
weighted avg	0.635266	99

Confusion Matrix (baris = label asli, kolom = prediksi):



g. Analisis

- **Kelas terkuat:** `acne` (F1 **0.77**) dan `sensitive` (F1 **0.71**). Keduanya punya ciri visual yang relatif khas (tekstur jerawat; kemerahan), sehingga lebih mudah dipisahkan.
- **Sumber error utama:** trio `dry` / `normal` / `oily` saling **tumpang-tindih**. Pada confusion matrix terlihat `dry` 14 benar tapi 5 bocor ke `oily`; `oily` 11 benar dengan 7 bocor ke `dry`.
- **normal paling lemah** (recall **0.25**) — dari 20 sampel hanya 5 benar; sering tertukar menjadi `dry` (7) atau `oily` (6).
- **dry menjadi "keranjang" over-prediksi** — banyak kelas lain salah diprediksi sebagai `dry` (precision rendah 0.44 meski recall tinggi 0.70).
- Hal ini **wajar**: perbedaan visual antara kulit `dry`, `normal`, dan `oily` memang **halus** dan sangat bergantung pencahayaan/kualitas foto.

h. Keterbatasan

1. **Test set kecil** (~20 gambar/kelas, total 99) → angka metrik **berisik**; selisih beberapa gambar dapat menggeser persentase cukup besar.
2. **Bias sumber pada sensitive** — kelas ini berasal dari sumber berbeda (rosacea + redness), sehingga model bisa saja belajar **ciri sumber/dataset**, bukan murni "sensitivitas kulit". **Uji sebenarnya** adalah foto wajah baru di luar dataset.
3. **Fine-tuning belum efektif** — pada lr 1e-5, fase 2 tidak meningkatkan akurasi validasi.
4. Model yang disimpan adalah **epoch terakhir**, bukan epoch dengan validasi terbaik.

i. Rekomendasi Perbaikan

1. **Perbaiki data dry/normal/oily** (terutama `normal`): tambah jumlah, perbaiki kualitas & konsistensi pencahayaan, kurangi ambiguitas label.
2. **Fine-tuning lebih agresif & cerdas**: coba lr **1e-4**, dan gunakan ModelCheckpoint/EarlyStopping untuk **menyimpan model dengan val accuracy terbaik** (bukan epoch terakhir).
3. **Kumpulkan foto kulit sensitif asli** untuk menggantikan proxy redness/rosacea, agar kelas `sensitive` benar-benar merepresentasikan target aplikasi.
4. **Pertimbangkan konsolidasi kelas** (mis. menggabungkan kategori yang ambigu) bila sesuai dengan kebutuhan produk QayraMakeUp.

Laporan ini dibuat berdasarkan `training_log.txt`, `evaluate_report.txt`, `confusion_matrix.png`, `labels.txt`, dan script di folder `tools/`. Angka diambil langsung dari artefak hasil training/evaluasi.