

Laporan Proyek — Klasifikasi Kondisi Kulit Wajah (MobileNetV2 → TFLite)

Proyek: QayraMakeUp — TensorFlow MobileNetV2 **Tanggal:** 7 Juli 2026

a. Tujuan Proyek

Membangun model klasifikasi **kondisi kulit wajah** ke dalam 5 kategori — **acne, dry, normal, oily, sensitive** — menggunakan arsitektur **MobileNetV2** dengan *transfer learning*, lalu mengekspornya ke **TensorFlow Lite** (**skin_condition.tflite**) agar ringan dan dapat dijalankan di perangkat mobile/edge untuk aplikasi **QayraMakeUp**.

Model menerima input gambar wajah **224×224 piksel RGB** (dinormalkan ke rentang **[0,1]**) dan menghasilkan probabilitas *softmax* untuk 5 kelas.

b. Dataset & Sumbernya

Dataset dibangun secara bertahap dari berbagai sumber Kaggle dan Roboflow. Kelas **sensitive** tidak memiliki dataset visual "kulit sensitif" yang valid, sehingga digunakan **proxy** berbasis kemerahan kulit:

Kelas	Sumber	Keterangan
oily, dry, normal	Kaggle — <i>Oily-Dry-and-Normal-Skin-Types</i> + Roboflow Universe	dataset wajah penuh
acne	Kaggle — <i>Acne Dataset</i> + Roboflow Universe	banyak <i>close-up</i> kulit
sensitive	proxy: <i>redness</i> (TrainingDataPro) + <i>rosacea</i> (Roboflow)	tidak ada dataset "sensitif" langsung

Penambahan dataset secara bertahap

- **Batch 1 (V6):** penambahan dari Kaggle/Roboflow untuk seluruh 5 kelas → total ~5.440 gambar. Akurasi melonjak dari 60,58% → **71,22%** (+10,64 poin).
- **Batch 2 (V7–V8):** penambahan dari Kaggle batch kedua + Roboflow untuk kelas dry, normal, dan oily → total **8.917 gambar**. Akurasi meningkat dari 71,22% → **74,39%** → **77,17%** setelah optimalisasi hyperparameter.

Tantangan kelas **sensitive** dan penanganannya

- **Masalah awal:** sumber *redness* hanya berisi **30 foto dari 10 orang** (3 angle per orang). Jumlah dan keragaman ini terlalu kecil dan sangat rawan **kebocoran data (*leakage*)** bila foto orang yang sama tersebar antar split.
- **Penambahan sumber:** ditambahkan kelas **rosacea** dari dataset Roboflow *facial-skin-diseases* (kelas lain seperti acne/eksim/herpes/panu **diabaikan**).

- **Split *group-aware* (anti-leakage):** pembagian train/val/test dilakukan **per grup** sehingga semua gambar dari satu subjek/satu gambar asli (termasuk augmentasinya) **selalu berada di split yang sama**.
- **Augmentasi hanya di train:** bagian *train* **sensitive** diaugmentasi hingga genap, sedangkan **val & test memakai gambar asli saja** (tidak diaugmentasi) agar evaluasi jujur.

c. Pipeline Kurasi Data

Script: `tools/prepare_dataset.py`

1. **Kumpulkan pool** per kelas dari sumber mentah — Kaggle dan Roboflow Universe.
2. **Deteksi wajah** — detektor OpenCV DNN res10 SSD. Gambar tanpa wajah terdeteksi tetap dibuang (dihitung).
3. **Crop wajah** → **resize 224×224**, normalisasi semua gambar ke `.jpg`.
4. **Dedup perceptual-hash** untuk menghilangkan gambar duplikat.
5. **Pembersihan manual** — menghapus gambar non-face, screenshot, stock photo, dan gambar dengan kategori salah (mis. eczema di folder sensitive).

d. Pembagian Akhir Dataset (70 / 20 / 10)

Dataset final (V8) setelah seluruh batch digabungkan dan dibersihkan:

Kelas	Train	Val	Test	Total
acne	565	162	77	804
dry	1.445	417	208	2.070
normal	2.029	580	296	2.905
oily	1.785	511	257	2.553
sensitive	405	115	65	585
TOTAL	6.229	1.785	903	8.917

Total: **6.229 train / 1.785 val / 903 test** (8.917 gambar). **Ketimpangan antar kelas:** **normal** paling banyak (**2.905**), **sensitive** paling sedikit (**585** — 5× lebih sedikit dari normal). Ditangani dengan **class_weight dinamis** yang di-*clamp* pada rentang **[0.8, 1.5]** untuk mencegah bobot terlalu ekstrem yang dapat mendistorsi pembelajaran.

e. Training

Arsitektur: MobileNetV2 (bobot ImageNet, `include_top=False`, *base di-freeze*) + head:

`GlobalAveragePooling2D` → `Dense(128, ReLU)` → `Dropout(0.3)` → `Dense(5, softmax)`.

Hyperparameter & pipeline (V8 — final):

- **Fase 1 (feature extraction):** 30 epoch, optimizer **Adam (lr default)**, *base* dibekukan. **EarlyStopping** `patience=7` (`restore_best_weights=True`). Loss: **Focal Loss (gamma=2.0)**. Augmentasi train: rotasi

20°, zoom 0.2, horizontal flip, brightness [0.8–1.2], width/height shift 0.1, shear 0.1.

- **Fase 2 (fine-tuning):** *unfreeze* 50 layer terakhir, Adam $\text{lr}=5\text{e-}5$, maks 20 epoch, **EarlyStopping** patience=5. Loss: **Focal Loss (gamma=2.0)**. **Terbukti efektif** — fine-tuning berhasil meningkatkan val accuracy dari 65,00% → **75,56%** (+10,56 poin) dan test accuracy menjadi **77,17%**.
- **ModelCheckpoint(save_best_only=True)** dipakai di **kedua fase dengan instance yang sama** → *skin_model_finetuned.h5* hanya ditimpa bila ada epoch yang **benar-benar lebih baik**, sehingga melindungi hasil dari fase mana pun.
- **class_weight** dihitung **dinamis** dari jumlah train aktual (*balanced*), kemudian di-*clamp* ke rentang **[0.8, 1.5]**.
- **Dropout 0.3** — diturunkan dari 0.5 untuk mengurangi underfitting.
- **Focal Loss (gamma=2.0)** untuk menangani ketidakseimbangan kelas.

Ringkasan hasil per fase (V8):

Fase	Train acc	Val acc
Fase 1 — awal (ep1)	~0.40	~0.43
Fase 1 — terbaik (ep27)	~0.63	~0.65 ← model fase 1 terbaik
Fase 1 — EarlyStopping	ep27	—
Fase 2 — terbaik (ep19)	~0.82	~0.76 ← model final
Fase 2 — EarlyStopping	ep20	—

Temuan utama:

- **Fine-tuning kini efektif** — berbeda dengan V5 di mana fine-tuning selalu menurunkan performa. Dengan dataset 8.917 gambar dan $\text{lr}=5\text{e-}5$, fine-tuning memberikan peningkatan val accuracy dari 65% → 76% dan test accuracy dari 65,48% (sebelum optimalisasi) menjadi **77,17%**.
- **class_weight clamp [0.8–1.5] penting** — tanpa clamping, model dengan dataset tidak seimbang mengalami distorsi: terlalu takut salah prediksi kelas minoritas dan terlalu abai pada kelas mayoritas, menjatuhkan akurasi ke 65,48%.
- **Epoch lebih panjang + patience lebih tinggi membantu** — Fase 1 30 epoch dengan patience=7 memberi model cukup waktu untuk konvergensi penuh sebelum masuk fine-tuning.
- **ReduceLROnPlateau tidak membantu** — menurunkan akurasi dari 74,39% → 73,27%.
- **Model final** (*skin_model_finetuned.h5*) berasal dari **Fase 2 epoch 19**, val accuracy **75,56%** pada data validasi — dan **77,17%** pada test set.

f. Evaluasi di Test Set

Script: *tools/evaluate.py* — 898 gambar test, *shuffle=False*, tanpa augmentasi. Hasil **final (V8)**: dataset 8.917 gambar dengan fine-tuning optimal.


Akurasi keseluruhan: 77,17%.

Kelas	Precision	Recall	F1-score	Support
acne	0.89	0.82	0.85	76

Kelas	Precision	Recall	F1-score	Support
dry	0.67	0.85	0.75	207
normal	0.81	0.78	0.80	295
oily	0.77	0.66	0.71	256
sensitive	0.88	0.89	0.88	64
accuracy	–	–	0.77	898
macro avg	0.80	0.80	0.80	898
weighted avg	0.78	0.77	0.77	898

Model akhir berasal dari Fase 2 (fine-tune) epoch 19. Fine-tuning kini terbukti efektif setelah dataset mencapai ukuran yang memadai (5.440+ gambar).

Confusion Matrix (baris = label asli, kolom = prediksi):



Matriks (labelurut: acne, dry, normal, oily, sensitive):

```
[[ 62  3  1  3  7]
 [  1 175 16 15  0]
 [  1  33 230 31  0]
 [  5  45  36 169  1]
 [  1  5  0  1 57]]
```

g. Analisis

- **Kelas terkuat & konsisten:** **sensitive** (F1 **0.88**, recall 89%, precision 88%) dan **acne** (F1 **0.85**, precision 89%). Keduanya kuat di semua iterasi karena ciri visual yang khas (kemerahan; tekstur jerawat).
- **Peningkatan paling dramatis — oily:** recall naik dari **20%** (V5) → **56%** (V7) → **66%** (V8). Kenaikan +46 poin recall, dengan hanya 45 dari 256 sampel oily yang kini salah diprediksi sebagai dry (sebelumnya 65 di V7). F1-score naik dari 0,30 → 0,66 → **0,71**.
- **Sumber error utama — trio dry/normal/oily masih tumpang-tindih:** pada confusion matrix V8, normal banyak bocor ke oily (31) dan dry (33); oily bocor ke dry (45) dan normal (36). Tumpang-tindih ini adalah **batas alami visual**.
- **Semua kelas kini di atas F1 0,70** — tidak ada lagi kelas "sangat lemah" seperti di iterasi awal. Ini menunjukkan model sudah mencapai keseimbangan yang baik.
- **Fine-tuning kini efektif.** Berbeda dengan dataset kecil (V5, 2.084 gambar) di mana fine-tuning selalu menurunkan performa, pada dataset besar (8.917 gambar) fine-tuning dengan $lr=5e-5$ berhasil memberikan peningkatan +2,78 poin (74,39% → 77,17%).
- **Cleaning manual terlalu agresif sempat merusak hasil (V3).** Pembersihan menghapus ~70% data **acne**, menjatuhkan akurasi ke **46,72%**. Dipulihkan dengan menambah data baru dari tahap *staging* di V4.
- **Penambahan dataset adalah strategi paling efektif.** Penambahan dari 2.084 → 5.440 gambar (V5→V6) menghasilkan lonjakan akurasi +10,64 poin (60,58% → 71,22%) — peningkatan terbesar sepanjang iterasi.
- **Augmentasi lebih kaya + epoch lebih panjang + fine-tuning optimal** berkontribusi pada hasil terbaik **77,17%** (V8).

h. Keterbatasan

1. **Test set tetap berisik** (898 gambar) — meskipun 4× lebih besar dari V5 (208), selisih beberapa gambar masih dapat menggeser persentase, terutama untuk kelas minoritas (sensitive: 65 test).
2. **Bias sumber pada sensitive** — kelas ini berasal dari sumber berbeda (rosacea + redness), sehingga model bisa saja belajar **ciri sumber/dataset**, bukan murni "sensitivitas kulit".
3. **Kelas oily tetap yang paling menantang** (recall **66%**) — kemiripan visual dengan dry dan normal masih menjadi sumber error utama; kilap minyak sulit terdeteksi dari foto pencahayaan biasa.
4. **Dataset tidak seimbang** — normal (2.905) 5× lebih banyak dari sensitive (585). Clamp `class_weight` [0.8–1.5] membantu namun bukan solusi optimal.
5. **Fine-tuning hanya efektif pada dataset besar** — pada dataset kecil (❤️ .000 gambar), fine-tuning konsisten menurunkan performa. Temuan ini penting untuk penelitian serupa di masa depan.

6. **Arsitektur MobileNetV2 mulai mendekati batas** — peningkatan lebih lanjut kemungkinan membutuhkan arsitektur yang lebih canggih (EfficientNet, ViT).

i. Rekomendasi Perbaikan

1. **Pertahankan strategi fine-tuning saat ini** — $lr=5e-5$, 20 epoch, unfreeze 50 layer terakhir — yang terbukti efektif pada dataset besar.
2. **Prioritaskan penambahan data oily** dengan kilap wajah yang jelas terlihat untuk menaikkan recall yang masih 66%.
3. **Tambah data sensitive asli** (bukan proxy redness/rosacea) untuk mengurangi bias sumber dan meningkatkan representasi.
4. **Pertimbangkan arsitektur yang lebih canggih** — EfficientNetV2, ConvNeXt, atau Vision Transformer — untuk melampaui batas MobileNetV2.
5. **Implementasikan cross-validation** (k-fold) untuk estimasi performa yang lebih stabil dan mengurangi ketergantungan pada satu split test.
6. **Eksplorasi ensemble model** — menggabungkan beberapa model dengan arsitektur berbeda dapat menaikkan akurasi 2–5 poin.

j. Riwayat Iterasi

Versi	Dataset	Akurasi	Catatan singkat
V1	1.000 foto (5 kelas)	58.59%	Baseline awal
V2	+killa92 (1.498 foto)	53.02%	Test set lebih berat & beragam
V3	+cleaning manual (1.214 foto)	46.72%	Cleaning terlalu agresif di acne
V4	+staging baru (2.084 foto)	58.65%	Augmentasi lebih kaya
V5	2.084 foto + Dropout 0.3 + Focal Loss	60.58%	Dropout 0.3 + Focal Loss
V6	+Kaggle Batch 1 (~5.440 foto)	71.22%	Lompatan +10.64 poin
V7	+Kaggle Batch 2 (8.917 foto)	74.39%	+clamp class weight [0.8–1.5]
V8	8.917 foto + fine-tune optimal	77.17%	Terbaik — $lr\ 5e-5$ + 20 ep FT

Pelajaran utama: **menambah data** adalah strategi paling efektif (+10.64 poin, V5→V6); **class weight clamping** menstabilkan training pada dataset tidak seimbang; **fine-tuning hanya efektif setelah dataset cukup besar** — pada dataset kecil, fine-tuning justru kontraproduktif.

Laporan ini dibuat berdasarkan *training_log.txt*, *evaluate_report.txt*, *confusion_matrix.png*, *labels.txt*, dan script di folder *tools/*. Angka diambil langsung dari artefak hasil training/evaluasi.