

Laporan Proyek — Klasifikasi Kondisi Kulit Wajah (MobileNetV2 → TFLite)

Proyek: QayraMakeUp — TensorFlow MobileNetV2 **Tanggal:** 17 Juni 2026

a. Tujuan Proyek

Membangun model klasifikasi **kondisi kulit wajah** ke dalam 5 kategori — **acne, dry, normal, oily, sensitive** — menggunakan arsitektur **MobileNetV2** dengan *transfer learning*, lalu mengekspornya ke **TensorFlow Lite** (**skin_condition.tflite**) agar ringan dan dapat dijalankan di perangkat mobile/edge untuk aplikasi **QayraMakeUp**.

Model menerima input gambar wajah **224×224 piksel RGB** (dinormalkan ke rentang **[0,1]**) dan menghasilkan probabilitas *softmax* untuk 5 kelas.

b. Dataset & Sumbernya

Empat kelas memiliki sumber visual yang jelas, namun **kelas sensitive tidak memiliki dataset visual "kulit sensitif" yang valid**, sehingga digunakan **proxy** berbasis kemerahan kulit:

Kelas	Sumber	Keterangan
oily, dry, normal	Kaggle — <i>Oily-Dry-and-Normal-Skin-Types</i>	dataset wajah penuh
acne	Kaggle — <i>Acne Dataset</i>	banyak <i>close-up</i> kulit
sensitive	proxy: <i>redness</i> (TrainingDataPro) + <i>rosacea</i> (Roboflow)	tidak ada dataset "sensitif" langsung

Tantangan kelas **sensitive** dan penanganannya

- **Masalah awal:** sumber *redness* hanya berisi **30 foto dari 10 orang** (3 angle per orang). Jumlah dan keragaman ini terlalu kecil dan sangat rawan **kebocoran data (leakage)** bila foto orang yang sama tersebar antar split.
- **Penambahan sumber:** ditambahkan kelas **rosacea** dari dataset Roboflow *facial-skin-diseases* (kelas lain seperti acne/eksim/herpes/panu **diabaikan**). Setelah kurasi, kelas **sensitive** menjadi **192 gambar bersih** yang berasal dari **±89 grup unik** (gabungan rosacea, redness, dan data kurasi lama).
- **Split group-aware (anti-leakage):** pembagian train/val/test dilakukan **per grup** menggunakan **group_id**, sehingga semua gambar dari satu subjek/satu gambar asli (termasuk augmentasinya) **selalu berada di split yang sama**.
- **Augmentasi hanya di train:** bagian **train sensitive** diaugmentasi hingga genap, sedangkan **val & test memakai gambar asli saja** (tidak diaugmentasi) agar evaluasi jujur.
- **Augmentasi menjaga sinyal warna:** karena kemerahan adalah **fitur warna**, augmentasi dibatasi pada transformasi **geometric** (flip horizontal, rotasi kecil, zoom/crop ringan, translasi) + **brightness ringan**, **TANPA mengubah hue/saturation** agar sinyal kemerahan yang justru ingin dipelajari tidak rusak.

c. Pipeline Kurasi Data

Script: `tools/prepare_dataset.py`

1. **Kumpulkan pool** per kelas dari sumber mentah + **salin** 100 gambar kurasi manual lama (copy, bukan dipindah).
2. **Deteksi wajah** — detektor diganti dari **Haar Cascade** → **OpenCV DNN res10 SSD** yang jauh lebih kuat. Dampaknya signifikan: jumlah *no-face* yang salah dibuang turun drastis (mis. **oily** dari 101 → 10). Gambar tanpa wajah terdeteksi tetap dibuang (dihitung).
3. **Crop wajah** → **resize 224×224**, normalisasi semua gambar ke **.jpg**.
4. **Dedup perceptual-hash** hanya untuk **4 kelas besar** (oily/dry/normal/acne); kelas **sensitive** **tidak** didedup agar augmentasi & variasi angle dipertahankan.
5. **Manifest** `dataset/_clean/manifest.csv` (`path`, `kelas`, `group_id`, `sumber`) sebagai dasar split *group-aware*.

Hasil kurasi (pool bersih): oily **350**, dry **369**, normal **376**, acne **250**, sensitive **192** (≈89 grup unik).

d. Pembagian Akhir Dataset (70 / 20 / 10)

Script: `tools/resplit_dataset.py` — resplit **group-aware** (seed=42, **anti-leakage**: semua file satu grup masuk split yang sama). Pembagian akhir dataset final (V4):

Kelas	Train	Val	Test	Total
acne	403	115	52	570
dry	296	89	40	425
normal	287	82	44	413
oily	289	84	40	413
sensitive	181	50	32	263
TOTAL	1.456	420	208	2.084

Total: **1.456 train / 420 val / 208 test** (2.084 gambar). **Ketimpangan antar kelas**: **acne** paling banyak (**570**), **sensitive** paling sedikit (**263**) — ditangani dengan **class_weight dinamis** di `train.py` (dihitung otomatis dari jumlah train tiap kelas). Split terbukti **bebas leakage** (irisasi grup antar split = 0).

Perbaiki labels.txt: file ditulis ulang dalam **urutan alfabet** (**acne**, **dry**, **normal**, **oily**, **sensitive**) agar **cocok dengan urutan baca flow_from_directory**. Ini sekaligus **menutup bug** urutan lama di mana **oily** dan **dry** tertukar.

e. Training

Arsitektur: MobileNetV2 (bobot ImageNet, `include_top=False`, *base di-freeze*) + head:
`GlobalAveragePooling2D` → `Dense(128, ReLU)` → `Dropout(0.3)` → `Dense(5, softmax)`.

Hyperparameter & pipeline (V5 — final):

- **Fase 1 (feature extraction):** 20 epoch, optimizer **Adam (lr default)**, *base* dibekukan. **EarlyStopping** patience=5 (**restore_best_weights=True**). Loss: **Focal Loss (gamma=2.0)**. Augmentasi train: rotasi 20°, zoom 0.2, horizontal flip, brightness [0.8–1.2], width/height shift 0.1, shear 0.1.
- **Fase 2 (fine-tuning):** *unfreeze* 50 layer terakhir, Adam **lr=1e-4**, maks 10 epoch, **EarlyStopping** patience=5. Loss: **Focal Loss (gamma=2.0)**. **Terbukti tidak efektif** — val accuracy fase 2 selalu < fase 1; EarlyStopping menghentikan di **epoch 7** fase 2. Model akhir selalu dari fase 1.
- **ModelCheckpoint(save_best_only=True)** dipakai di **kedua fase dengan instance yang sama** → *skin_model_finetuned.h5* hanya ditimpa bila ada epoch yang **benar-benar lebih baik**, sehingga melindungi hasil dari fase 2 yang merugikan.
- **class_weight** dihitung **dinamis** dari jumlah train aktual (*balanced*).
- **Dropout diturunkan dari 0.5 → 0.3** untuk mengurangi underfitting di validasi (selisih train acc ~70% vs val ~56% menunjukkan Dropout terlalu agresif memotong informasi).
- **Focal Loss (gamma=2.0)** ditambahkan untuk memberi bobot lebih besar pada sampel yang sulit diklasifikasi (kelas lemah seperti oily, dry). Hasilnya identik dengan categorical crossentropy — tidak merusak, tapi tidak membantu secara signifikan.

Ringkasan hasil per fase (V5):

Fase	Train acc	Val acc
Fase 1 — awal (ep1)	~0.39	~0.47
Fase 1 — terbaik (ep6)	~0.62	~0.57 ← model disimpan
Fase 1 — EarlyStopping	ep11	—
Fase 2 — terbaik (ep9)	~0.85	~0.58 (tidak mengalahkan fase 1)
Fase 2 — EarlyStopping	ep10	—

Temuan utama:

- **Overfitting ringan** terlihat dari selisih train acc (~60–68%) vs val acc (~57–58%) di akhir fase 1.
- **Dropout 0.3 → 0.5 terbukti membantu** — val accuracy fase 1 naik dari ~0.56 → ~0.57, dan akurasi test set naik dari 58.65% → **60.58%**.
- **Focal Loss tidak memberikan peningkatan signifikan** — hasil identik dengan categorical crossentropy. Tidak merusak, tapi tidak membantu untuk dataset ini.
- **Fine-tuning lr=1e-4 tetap tidak menaikkan val accuracy** (fase 2 terbaik **58%** < fase 1 terbaik **57%**). Konsisten di **3 percobaan** (lr=1e-5 maupun 1e-4); EarlyStopping menghentikan fase 2 lebih awal.
- **Model final** (*skin_model_finetuned.h5*) berasal dari **Fase 1 epoch 6**, val accuracy **57.38%** pada data validasi — dan **60.58%** pada test set.

f. Evaluasi di Test Set


Script: *tools/evaluate.py* — 208 gambar test, **shuffle=False**, tanpa augmentasi. Hasil **final (V5)**: dataset 2.084 gambar + train.py termodifikasi (Dropout 0.3 + Focal Loss).

Akurasi keseluruhan: 60.58%.

Kelas	Precision	Recall	F1-score	Support
acne	0.71	0.96	0.82	52
dry	0.38	0.50	0.43	40
normal	0.49	0.52	0.51	44
oily	0.62	0.20	0.30	40
sensitive	0.96	0.78	0.86	32
accuracy	–	–	0.61	208
macro avg	0.63	0.59	0.58	208
weighted avg	0.62	0.61	0.59	208

Model akhir berasal dari Fase 1 epoch 6. Fine-tuning tetap aktif di kode namun tidak efektif — model terbaik selalu dari fase 1, dan dilindungi `ModelCheckpoint(save_best_only=True)` sehingga fase 2 yang lebih buruk **tidak pernah menimpa** model terbaik.

Confusion Matrix (baris = label asli, kolom = prediksi):



Matriks (labelurut: acne, dry, normal, oily, sensitive):

```
[[50  2  0  0  0]
 [ 6 20 11  3  0]
 [ 3 15 23  2  1]
 [ 8 11 13  8  0]
 [ 3  4  0  0 25]]
```

g. Analisis

- **Kelas terkuat & konsisten:** **acne** (F1 **0.82**, recall 0.96) dan **sensitive** (F1 **0.86**). Keduanya **kuat di SEMUA iterasi** (V1–V5) karena ciri visualnya khas (tekstur jerawat; kemerahan), sehingga paling mudah dipisahkan.
- **Sumber error utama — trio dry/normal/oily tumpang-tindih (konsisten di semua iterasi):** pada confusion matrix V5, **oily** hanya 8/40 benar dengan **13 bocor ke normal**; **dry** 20/40 benar dengan 11 bocor ke **normal**. Kini **normal** menjadi "keranjang" **over-prediksi** (banyak oily/dry salah jadi normal).
- **oily paling lemah** (recall **0.20**) — kemiripan visual dengan **normal** sangat tinggi; kilap minyak sulit terlihat pada foto pencahayaan biasa.
- Tumpang-tindih ini adalah **batas alami visual**: perbedaan kulit *dry/normal/oily* memang halus dan sangat bergantung pencahayaan/kualitas foto — bukan sekadar kekurangan model.
- **Dropout 0.3 → 0.5 terbukti membantu.** Penurunan Dropout dari 0.5 → 0.3 mengurangi underfitting di validasi (selisih train acc ~70% vs val ~56%), menaikkan akurasi test set dari 58.65% → **60.58%** (+1.93 poin).
- **Focal Loss tidak memberikan peningkatan signifikan.** Meskipun dirancang untuk fokus pada sampel yang sulit diklasifikasi (kelas lemah seperti oily, dry), hasilnya identik dengan categorical crossentropy. Tidak merusak, tapi tidak membantu untuk dataset ini.
- **Fine-tuning terbukti tidak menaikkan val accuracy (3× percobaan).** Fase 2 (fine-tune) **selalu** menghasilkan val accuracy < **fase 1**, termasuk setelah lr dinaikkan ke 1e-4. Karena dilindungi `ModelCheckpoint(save_best_only=True)`, fase 2 yang lebih buruk **tidak merusak** hasil — model terbaik selalu diambil dari fase 1 — namun fine-tuning **tidak memberi manfaat** untuk dataset sekecil ini.
- **Cleaning manual terlalu agresif sempat merusak hasil (V3).** Pembersihan menghapus ~70% data **acne**, menjatuhkan akurasi ke **46.72%**. Dipulihkan dengan menambah data baru dari tahap *staging* (imtkaggleteam) di V4.
- **Augmentasi lebih kaya + fase 1 lebih panjang membantu.** Tambahan augmentasi (*brightness, shift, shear*) dan fase 1 **20 epoch** berkontribusi pada hasil terbaik **60.58%** (V5).

h. Keterbatasan

1. **Test set masih terbatas** (208 gambar) → metrik tetap **berisik**, terutama kelas minoritas; selisih beberapa gambar dapat menggeser persentase.
2. **Bias sumber pada sensitive** — kelas ini berasal dari sumber berbeda (rosacea + redness), sehingga model bisa saja belajar **ciri sumber/dataset**, bukan murni "sensitivitas kulit". **Uji sebenarnya** adalah foto wajah baru di luar dataset.

3. **Fine-tuning MobileNetV2 tidak efektif untuk dataset kecil ini** — val accuracy fase 2 **selalu lebih rendah** dari fase 1 (terbukti pada lr 1e-5 maupun 1e-4). Manfaatnya nol; hanya tidak merusak karena dilindungi `ModelCheckpoint(save_best_only=True)`.
4. **Cleaning manual berisiko membuang terlalu banyak data kelas minoritas** — pada V3, **acne** kehilangan ~70% datanya sehingga akurasi anjlok ke **46.72%** sebelum dipulihkan dengan data baru.
5. **Kelas oily tetap sulit dikenali** (recall 20%) karena kemiripan visual dengan **normal** sangat tinggi.

i. Rekomendasi Perbaikan

1. **Nonaktifkan atau ganti strategi fine-tuning.** Karena fase 2 tidak pernah membantu, pertimbangkan **unfreeze lebih sedikit layer** (mis. 10–20 layer terakhir saja) atau pakai *learning rate* adaptif seperti `ReduceLROnPlateau` alih-alih lr tetap.
2. **Lakukan cleaning manual secara bertahap dan hitung ulang jumlah per kelas sebelum menghapus**, agar kelas minoritas (seperti **acne** di V3) tidak kehilangan terlalu banyak data dan menjatuhkan akurasi.
3. **Prioritaskan penambahan data oily** dengan **kilap wajah yang jelas terlihat** (selfie pencahayaan terang) untuk menaikkan recall kelas ini yang masih rendah (20%).
4. **Perbaiki data dry/normal/oily** secara umum: tambah jumlah, perbaiki kualitas & konsistensi pencahayaan, kurangi ambiguitas label.
5. **Kumpulkan foto kulit sensitif asli** untuk menggantikan proxy redness/rosacea, agar kelas **sensitive** benar-benar merepresentasikan target aplikasi.
6. **Pertimbangkan konsolidasi kelas** (mis. menggabungkan kategori yang ambigu) bila sesuai dengan kebutuhan produk QayraMakeUp.

j. Riwayat Iterasi

Versi	Dataset	Akurasi	Catatan singkat
V1	1.000 foto (5 kelas)	58.59%	Baseline awal
V2	+killa92 (1.498 foto)	53.02%	Test set lebih berat & beragam
V3	+cleaning manual (1.214 foto)	46.72%	Cleaning terlalu agresif di acne
V4	+staging baru (2.084 foto)	58.65%	Augmentasi lebih kaya
V5	2.084 foto + Dropout 0.3 + Focal Loss	60.58%	Terbaik — Dropout 0.3 + Focal Loss

Pelajaran utama: menambah data **tanpa menjaga keseimbangan kelas** (V2) atau **membuang data minoritas berlebihan** (V3) justru menurunkan akurasi; perbaikan nyata (V4→V5) datang dari **modifikasi hyperparameter** (Dropout 0.3, Focal Loss), bukan dari fine-tuning atau penambahan data baru.

Laporan ini dibuat berdasarkan `training_log.txt`, `evaluate_report.txt`, `confusion_matrix.png`, `labels.txt`, dan script di folder `tools/`. Angka diambil langsung dari artefak hasil training/evaluasi.